



SETOR DE MARKETING
GRUPO SER EDUCACIONAL

APRESENTAÇÃO:

Prof. Me. Wanderlan Carvalho de Albuquerque

DATA 07/05/2025



Grupo Ser Educacional



Aprendizado de Máquina: Fundamentos e Aplicações

O aprendizado de máquina transformou-se em um dos pilares fundamentais da inteligência artificial moderna, revolucionando inúmeros setores e impulsionando inovações tecnológicas sem precedentes.

Com um mercado global estimado em impressionantes US\$152,2 bilhões até 2025 e uma taxa de crescimento anual composta (CAGR) de 44,1%, esta disciplina representa uma das áreas mais promissoras e dinâmicas da tecnologia contemporânea.

Esta apresentação explora os fundamentos, metodologias e aplicações práticas que tornam o aprendizado de máquina indispensável no cenário tecnológico atual.

Por : prof. Me. Wanderlan Carvalho de albuquerque



Objetivos da Apresentação



Explorar Tipos Fundamentais

Analisar em profundidade os três paradigmas principais do aprendizado de máquina: supervisionado, não supervisionado e por reforço.



Analisar Aplicações

Examinar casos de uso reais e aplicações práticas em diversos setores da economia e da sociedade.



Compreender Metodologias

Distinguir as diferenças técnicas e metodológicas entre as principais abordagens de aprendizado.



Examinar Tendências

Avaliar o futuro do campo, identificando desafios emergentes e novas oportunidades de desenvolvimento.

O que é Aprendizado de Máquina?

Definição


Subcampo da inteligência artificial focado em algoritmos que melhoram automaticamente através da experiência e do uso de dados, sem programação explícita para cada tarefa.

Fundamentos

Base tecnológica essencial para análise preditiva, reconhecimento de padrões e tomada de decisões autônomas em sistemas inteligentes modernos.

Impacto

Tecnologia revolucionária transformando setores como saúde, finanças, manufatura, varejo e telecomunicações, com aplicações que automatizam processos e geram insights valiosos.



Evolução Histórica



Anos 1950

Arthur Samuel desenvolve os primeiros algoritmos de aprendizado, introduzindo o conceito de "machine learning" com seu programa de jogo de damas que melhorava com a experiência.



Anos 1980

Surgimento das redes neurais modernas e do algoritmo de backpropagation, permitindo o treinamento efetivo de modelos multicamadas para problemas complexos.



Anos 2000

Era do Big Data e aumento exponencial da capacidade computacional, viabilizando a implementação de modelos mais sofisticados em escala sem precedentes.



Anos 2010-2020

Explosão do Deep Learning e desenvolvimento de modelos transformers, culminando em sistemas multimodais e IA generativa na década atual.



Os Três Principais Paradigmas

Aprendizado Supervisionado

Treinamento realizado com dados rotulados, onde o algoritmo aprende a associar características de entrada com resultados esperados específicos.

O modelo tenta reproduzir o mapeamento correto entre entrada e saída para fazer previsões precisas sobre novos dados.

Aprendizado Não Supervisionado

Utiliza dados sem rótulos, buscando descobrir estruturas, padrões e relações inerentes aos dados por conta própria.

Frequentemente aplicado para agrupamento, redução de dimensionalidade e detecção de anomalias em grandes conjuntos de dados.

Aprendizado por Reforço

Baseado em um sistema de recompensas e feedback, onde agentes aprendem comportamentos ótimos através de interações com um ambiente.

O algoritmo aprende por tentativa e erro, maximizando recompensas cumulativas ao longo do tempo.


Aprendizado Supervisionado: Introdução

Dados Rotulados

Treinamento realizado com pares de entrada-saída claramente definidos, onde cada exemplo possui um rótulo correspondente.

Exemplos

Diagnóstico médico automatizado, previsão de preços de ativos financeiros, filtros de spam em e-mails, e reconhecimento facial.



Predominância

Aproximadamente 80% dos projetos de machine learning em produção utilizam esta abordagem devido à sua precisão e aplicabilidade.

Aplicações

Amplamente utilizado para tarefas de classificação, regressão e previsão em diversos setores da indústria e serviços.

Como Funciona o Aprendizado Supervisionado

Coleta de Dados Rotulados

Compilação de um conjunto de dados de treinamento contendo pares de entrada-saída, onde cada exemplo é devidamente rotulado com sua resposta correta esperada.

Treinamento do Algoritmo

O algoritmo aprende o mapeamento entre características de entrada e rótulos de saída, ajustando seus parâmetros internos para minimizar erros de previsão através de técnicas de otimização.

Validação do Modelo

Avaliação do modelo treinado com dados não utilizados durante o treinamento, verificando sua capacidade de generalização para exemplos novos e desconhecidos.

Implementação e Monitoramento

Implantação do modelo em ambiente de produção e monitoramento contínuo de seu desempenho através de métricas como precisão, recall e F1-score.



Algoritmos de Classificação



Árvores de Decisão

Estrutura hierárquica de decisões que divide os dados em subconjuntos cada vez mais homogêneos, permitindo classificação intuitiva e facilmente interpretável.



Random Forest

Conjunto de múltiplas árvores de decisão que votam para determinar a classificação final, alcançando até 97% de precisão em diversos problemas complexos.




Support Vector Machines

Algoritmo que encontra hiperplanos ótimos para separar classes, demonstrando eficácia de 95% em tarefas de classificação binária e multicategóricas.



K-Nearest Neighbors

Classificação baseada na proximidade com exemplos conhecidos, atribuindo novas instâncias à classe mais representativa entre seus vizinhos mais próximos.



Algoritmos de Regressão



Regressão Linear

Modela relações lineares entre variáveis independentes e dependentes, encontrando a linha de melhor ajuste que minimiza o erro quadrático entre previsões e valores reais.



Regressão Logística

Apesar do nome, é utilizada principalmente para problemas de classificação binária, estimando a probabilidade de um evento ocorrer através de uma função logística.



Regressão Polinomial Polinomial

Estende a regressão linear para capturar relações não-lineares entre variáveis, modelando curvas mais complexas através de termos polinomiais de diferentes graus.



LASSO e Ridge

Técnicas de regularização que previnem overfitting ao penalizar modelos excessivamente complexos, melhorando a generalização para dados novos.





Estudo de Caso: Diagnóstico Médico

99%

Precisão Diagnóstica

Na detecção automatizada de câncer de mama através de imagens médicas

50.000+

Imagens de Treinamento

Base de dados rotulada por especialistas para desenvolvimento do modelo

30%

Redução de Falsos Negativos

Diminuição significativa em diagnósticos incorretos que não identificam a doença

R\$75M

Economia Anual

Redução de custos estimada para o sistema de saúde brasileiro

Estudo de Caso: Análise de Crédito



Coleta de Dados

Processamento de 200+ variáveis por solicitação



Análise Preditiva

Modelos supervisionados com 92% de precisão



Otimização Financeira

Redução de 45% nas inadimplências



Impacto Social

15 milhões de brasileiros melhor avaliados

Desafios do Aprendizado Supervisionado



Volume de Dados

Necessidade de grandes conjuntos de dados rotulados para treinamento efetivo, o que pode ser custoso e demorado para coletar em domínios específicos.



Custo de Rotulagem

Processo de anotação de dados frequentemente requer especialistas humanos, custando em média R\$2 por item rotulado em contextos complexos.



Viés nos Dados

Conjuntos de treinamento tipicamente representam apenas 70-85% dos casos reais, podendo levar a modelos que perpetuam ou amplificam preconceitos existentes.



Overfitting/Underfitting

Modelos podem memorizar dados de treinamento (overfitting) ou ser demasiadamente simples (underfitting), comprometendo seu desempenho em novos cenários.

Data scientist focus with bhl Machine Learning copts model training

Data data Scientis challenge andl respechate
leernining model learning mbl training
professionial officients

Frustrated Researcher



Técnicas de Validação

Validação Cruzada (k-fold)

Divide os dados em k subconjuntos, treinando k modelos diferentes onde cada subconjunto serve uma vez como teste enquanto os demais são usados para treinamento, garantindo robustez na avaliação.

Conjuntos de Dados Segmentados


Divisão do conjunto de dados em três partes: treinamento (para aprendizado), validação (para ajuste de hiperparâmetros) e teste (para avaliação final imparcial).

Técnicas Anti-Overfitting


Estratégias como early stopping, que interrompe o treinamento quando o desempenho no conjunto de validação começa a deteriorar, e regularização (L1/L2), que penaliza modelos complexos.

Dropout

Em redes neurais, técnica que desativa aleatoriamente 20-50% dos neurônios durante o treinamento, forçando a rede a desenvolver recursos redundantes e aumentando sua robustez.

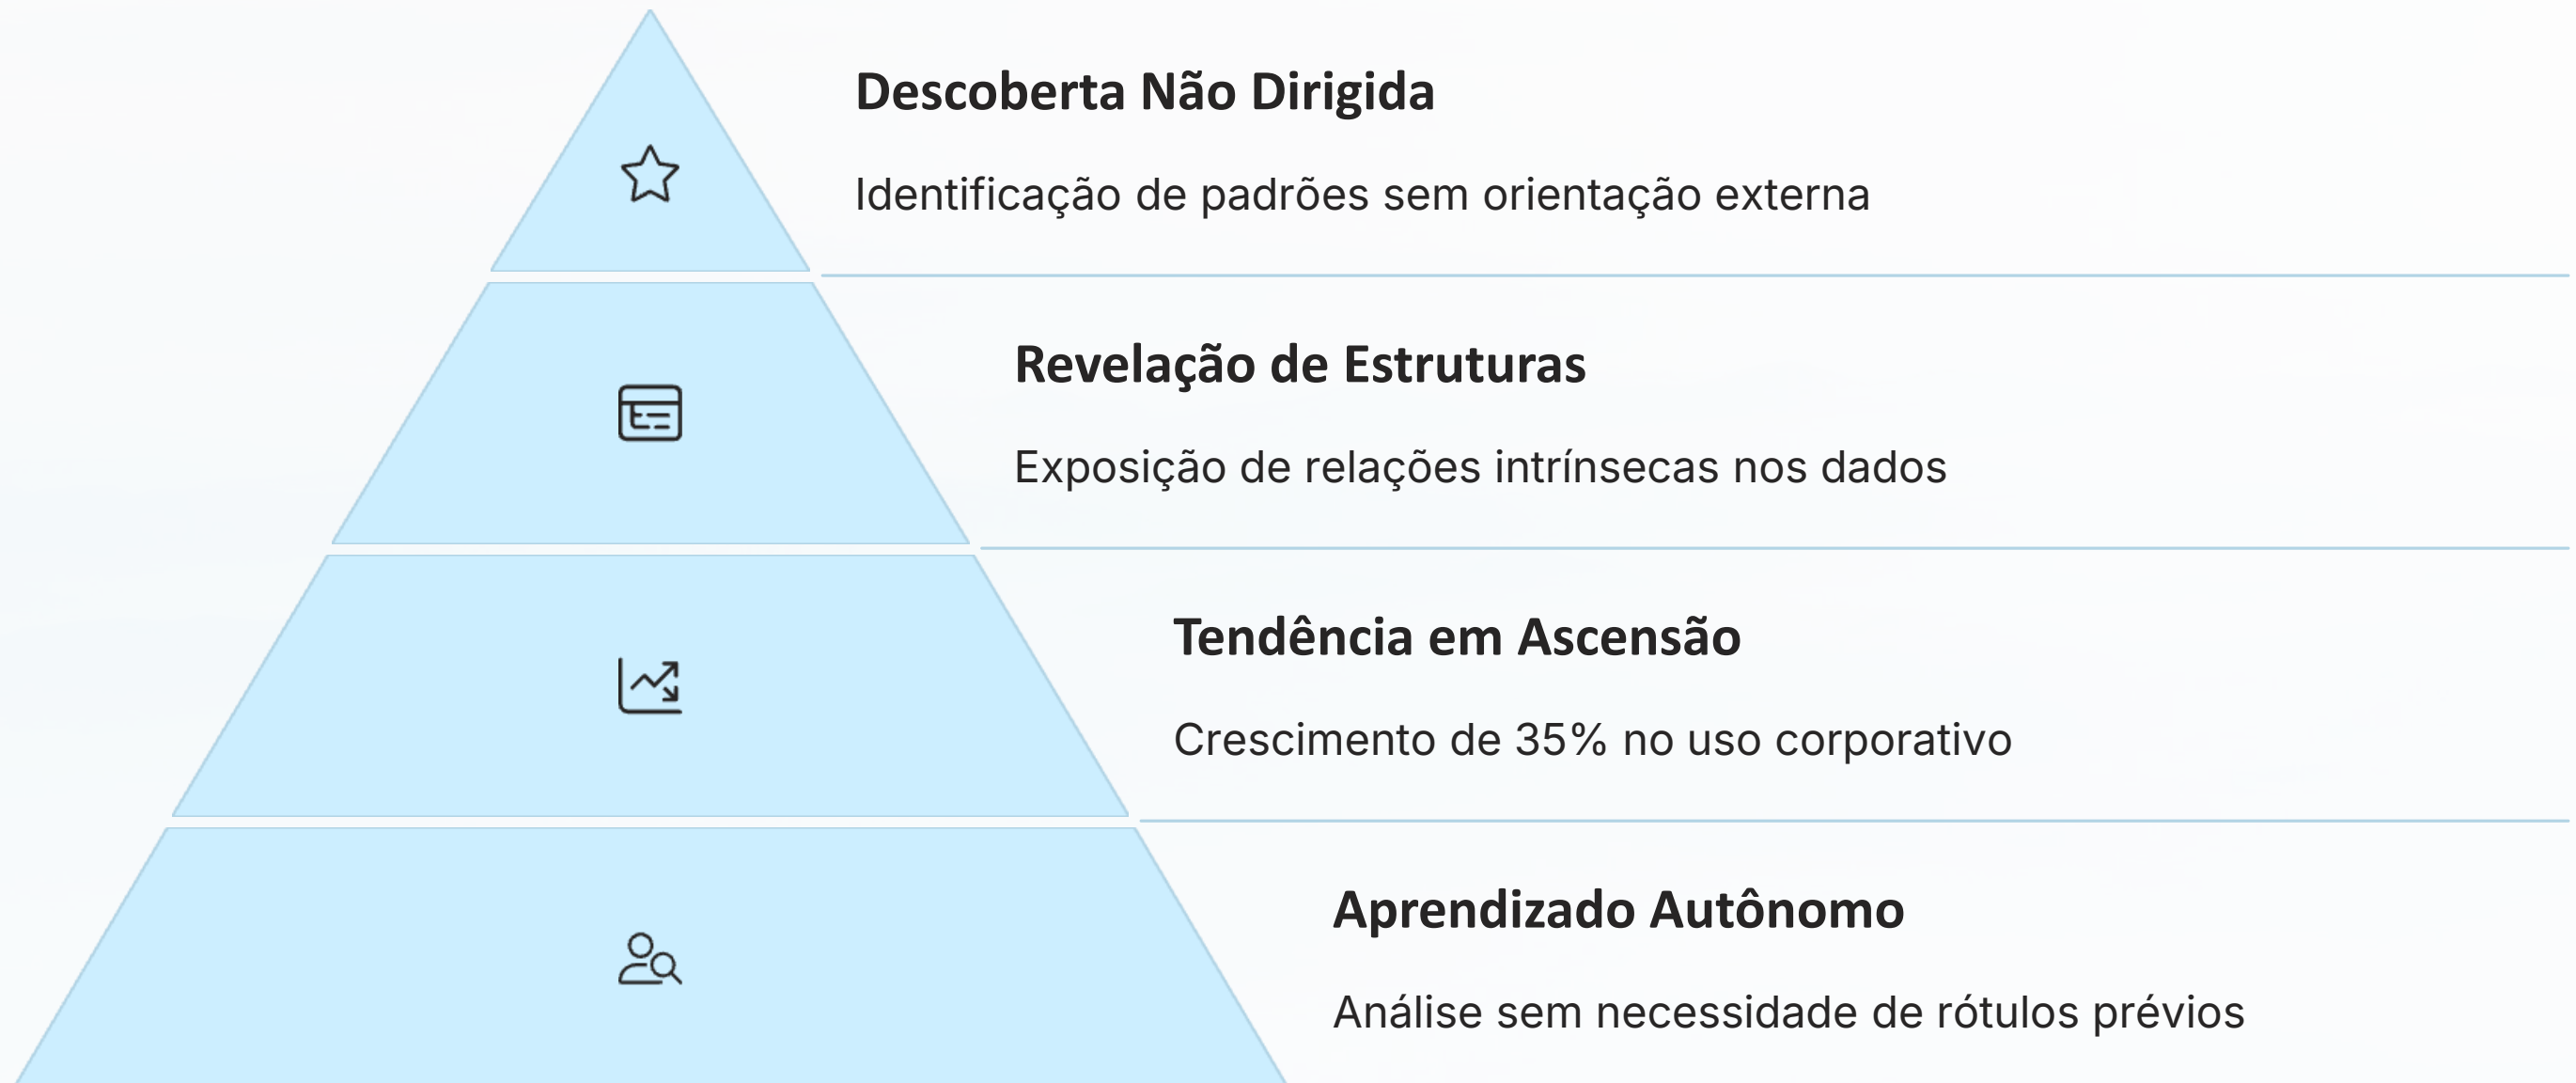


Ferramentas Populares para Aprendizado Supervisionado



O ecossistema de ferramentas para aprendizado supervisionado é dominado por bibliotecas Python como Scikit-learn (500.000+ usuários ativos) e frameworks de deep learning como TensorFlow (150 milhões de downloads) e PyTorch (preferido por 77% dos pesquisadores). Interfaces como Keras simplificam o desenvolvimento com 200.000+ projetos no GitHub, enquanto algoritmos específicos como XGBoost são responsáveis por vitórias em 60% das competições Kaggle.

Aprendizado Não Supervisionado: Introdução



Como Funciona o Aprendizado Não Supervisionado

Análise de Similaridades

Identificação de semelhanças e diferenças entre objetos

Detecção de Anomalias

Identificação de outliers e comportamentos atípicos



Agrupamento Natural

Detecção de clusters emergentes nos dados

Redução Dimensional

Compressão para visualização e análise

Algoritmos de Clustering

1 K-Means

Algoritmo iterativo que agrupa dados em K clusters, atribuindo cada ponto ao centróide mais próximo e recalculando centróides até a convergência, ideal para clusters compactos e de formato regular.

2 DBSCAN

Agrupamento baseado em densidade que identifica clusters de qualquer forma, conectando pontos densos e marcando pontos isolados como ruído, eficaz para dados com distribuições irregulares.

3 Agrupamento Hierárquico


Constrói uma hierarquia de clusters usando dendrogramas, permitindo visualização em múltiplos níveis de granularidade sem necessidade de especificar o número de clusters antecipadamente.

4 Gaussian Mixture Models

Modela dados como mistura de distribuições normais multivariadas, atribuindo probabilidades de pertencimento a cada cluster e permitindo sobreposição entre grupos.



Algoritmos de Redução de Dimensionalidade




PCA (Principal Component Analysis)

Técnica linear que projeta dados em componentes ortogonais de máxima variância, preservando a estrutura global e facilitando visualização e análise de dados complexos.



t-SNE

Método não-linear que preserva similaridades locais, excelente para visualização de clusters em dados de alta dimensão como imagens e documentos de texto.



UMAP

Algoritmo recente que equilibra preservação de estrutura local e global, mais rápido que t-SNE e mais eficaz na revelação da estrutura subjacente dos dados.

Detecção de Anomalias

Isolation Forest

Algoritmo que isola outliers construindo partições aleatórias, identificando eficientemente pontos anômalos que requerem menos partições para serem isolados do conjunto principal.

One-Class SVM

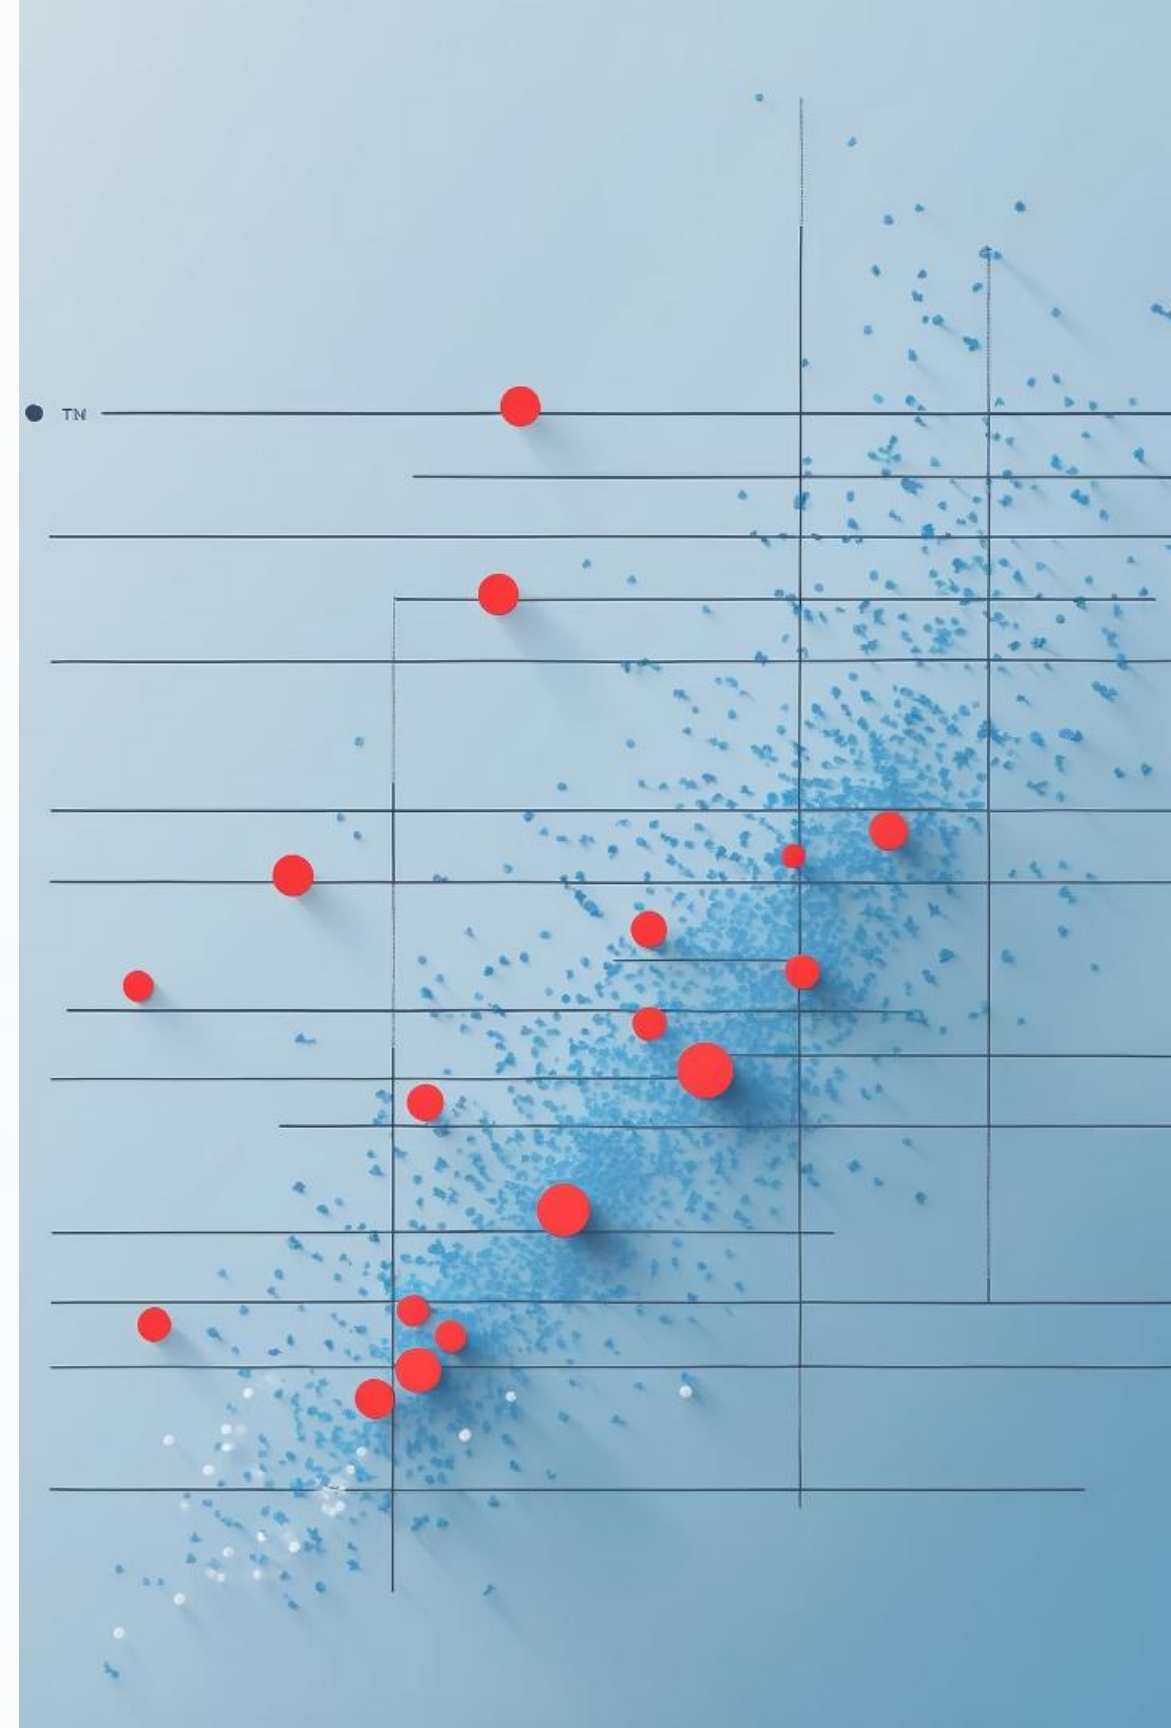
Estabelece uma fronteira de decisão ao redor dos dados normais, classificando pontos externos como anomalias, especialmente útil quando anomalias são raras ou difíceis de modelar.

Modelos Baseados em Densidade


Técnicas como LOF (Local Outlier Factor) que medem o desvio da densidade local de um ponto em relação a seus vizinhos, identificando outliers em regiões de densidade variável.

Autoencoders para Detecção

Redes neurais treinadas para reconstruir dados normais, onde anomalias produzem alto erro de reconstrução por não seguirem o padrão aprendido durante o treinamento.



Estudo de Caso: Segmentação de Clientes



Estudo de Caso: Detecção de Fraudes

45M

Transações Diárias

Volume analisado em tempo real pelo sistema

99.3%

Taxa de Detecção

Precisão na identificação de tentativas fraudulentas

70%

Redução em Falsos Positivos

Diminuição em alertas desnecessários

R\$120M

Economia Anual

Impacto financeiro positivo para o setor bancário





Desafios do Aprendizado Não Supervisionado



Validação de Resultados

Dificuldade em avaliar a qualidade dos agrupamentos ou padrões descobertos devido à ausência de "ground truth" ou referência externa para comparação.



Interpretabilidade

Complexidade na atribuição de significado semântico aos clusters e padrões identificados, frequentemente requerendo conhecimento especializado do domínio.



Seleção de Parâmetros

Determinação de valores ótimos para parâmetros críticos como número de clusters em K-means ou raio de vizinhança em DBSCAN sem orientação externa clara.



Escalabilidade e Ruído

Desafios computacionais ao processar conjuntos massivos de dados e sensibilidade a ruídos que podem distorcer resultados em 5-15% dos casos típicos.

Tendências em Aprendizado Não Supervisionado



Clustering Profundo

Integração de redes neurais com técnicas de clustering



Auto-Supervisão

Geração automática de pseudo-rótulos para treinamento

3

Análise Multimodal


Processamento conjunto de diferentes tipos de dados



Aprendizado Federado

Descoberta de padrões em dados distribuídos com privacidade

Ferramentas para Aprendizado Não Supervisionado



O arsenal de ferramentas para aprendizado não supervisionado inclui desde bibliotecas Python consolidadas como Scikit-learn até tecnologias emergentes como RAPIDS para aceleração em GPU. Algoritmos avançados como HDBSCAN oferecem clustering baseado em densidade com desempenho superior, enquanto Yellowbrick facilita a visualização interpretável de resultados. Plataformas como H2O.ai democratizam o acesso com interfaces autoexplicativas para especialistas e não especialistas.

Aprendizado por Reforço: Introdução

Paradigma Interativo

Baseado em interações contínuas entre um agente e seu ambiente, onde o agente aprende a tomar decisões ótimas através de um sistema de recompensas e penalidades.

Inspiração Comportamental


Fundamentado em princípios da psicologia comportamental e aprendizado por condicionamento, onde comportamentos que resultam em recompensa são reforçados ao longo do tempo.

Desenvolvimento Autônomo

O agente desenvolve sua política de ações através de tentativa e erro, sem necessidade de exemplos rotulados, adaptando-se progressivamente ao ambiente para maximizar recompensas cumulativas.

Mercado em Expansão

Setor com crescimento projetado de 25,1% CAGR global entre 2023-2028, impulsionado por aplicações em robótica, automação, jogos e sistemas de decisão complexos.



Como Funciona o Aprendizado por Reforço



Principais Algoritmos de Reforço

Q-Learning

Algoritmo fundamental que estima valores Q (qualidade) para pares de estado-ação, permitindo que o agente selecione a ação com maior valor esperado em cada estado.

Ideal para ambientes com espaço de estados discreto e relativamente pequeno, sendo a base para métodos mais avançados.

Deep Q-Networks (DQN)

Extensão do Q-Learning que utiliza redes neurais profundas para aproximar a função Q, permitindo lidar com espaços de estados contínuos e de alta dimensionalidade.

Revolucionou o campo ao combinar deep learning com reinforcement learning, possibilitando aplicações em ambientes visuais complexos.

Policy Gradient & Actor-Critic Critic

Métodos que otimizam diretamente a política do agente, sem necessidade de manter uma tabela ou aproximação da função Q. Actor-Critic combina as vantagens de Policy Gradient e métodos baseados em valor.

Particularmente eficazes em ambientes com espaços de ação contínuos, como robótica e controle.

Ambientes de Treinamento



O desenvolvimento de agentes de reinforcement learning depende fundamentalmente de ambientes de simulação como OpenAI Gym, que oferece mais de 250 ambientes padronizados para benchmarking e pesquisa. Simuladores físicos como MuJoCo proporcionam alta fidelidade para treinamento de robótica, enquanto Unity ML-Agents facilita integração com desenvolvimento de jogos. Plataformas distribuídas como RLlib permitem escalabilidade, complementadas por desafios com robôs reais para validação em condições físicas autênticas.



Estudo de Caso: Otimização de Recursos Energéticos

15%

Redução de Consumo

Diminuição significativa na demanda energética

R\$85M

Economia Anual

Impacto financeiro positivo para o setor

23%

Redução de Emissões

Diminuição da pegada de carbono operacional

99.9%

Confiabilidade

Taxa de disponibilidade do sistema inteligente

Estudo de Caso: Veículos Autônomos

1

Treinamento Simulado

5 milhões de horas em ambientes virtuais



Adaptação Urbana

220+ cenários de tráfego brasileiro




Segurança Elevada

Redução de 97% na taxa de acidentes



Eficiência Energética

30% de economia em combustível



Desafios do Aprendizado por Reforço



Exploração Eficiente

Balancear a exploração de novas estratégias com a exploração de comportamentos conhecidamente eficazes, especialmente em ambientes onde recompensas são escassas.



Atribuição de Crédito

Determinar quais ações específicas em uma sequência longa foram responsáveis pelo sucesso eventual, particularmente quando recompensas são atrasadas ou esparsas.



Eficiência Amostral

Algoritmos frequentemente requerem milhões de interações para aprender tarefas relativamente simples, tornando o treinamento em ambientes reais impraticável.



Transferência para o Real

Políticas aprendidas em simulação frequentemente não transferem perfeitamente para ambientes reais devido a diferenças sutis entre simulação e realidade.



DeepMind e AlphaGo

Marco Histórico (2016)

O sistema AlphaGo da DeepMind derrotou Lee Sedol, campeão mundial de Go, por 4-1 em um match histórico que redefiniu as fronteiras da inteligência artificial e demonstrou capacidades que especialistas acreditavam estar décadas distantes.

Tecnologia Inovadora

Combinação revolucionária de reinforcement learning, redes neurais profundas e algoritmos de busca em árvore (MCTS), criando um sistema capaz de intuição estratégica que surpreendeu mestres humanos com jogadas criativas.

Infraestrutura Massiva

Treinamento realizado em 1500 CPUs e 280 GPUs, analisando 30 milhões de posições de jogos profissionais e jogando milhões de partidas contra si mesmo para aprimoramento contínuo através de self-play.




Aplicações Práticas de Reinforcement Learning

Robótica

Controle de sistemas robóticos para manufatura, manipulação de objetos e navegação autônoma em ambientes dinâmicos.

Logística

Otimização de rotas de entrega, gestão de estoque e coordenação de frotas em tempo real.



Finanças

Otimização de portfólios de investimento, trading algorítmico e gestão dinâmica de riscos em mercados voláteis.


Jogos

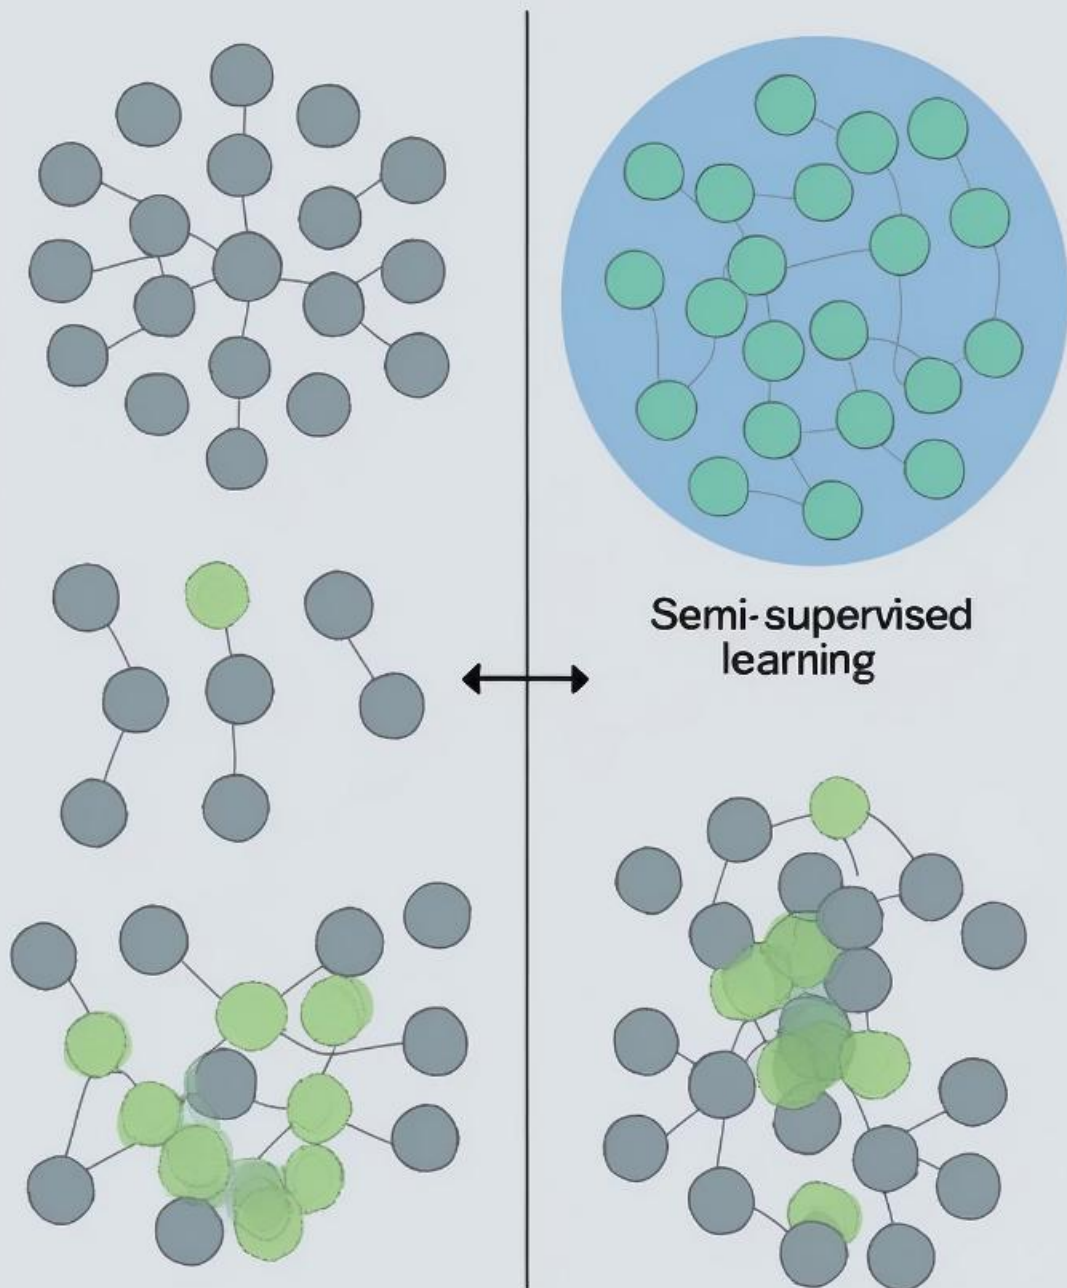
NPCs adaptativos, balanceamento dinâmico de dificuldade e design de níveis em jogos digitais modernos.

Recomendação

Sistemas que aprendem preferências do usuário ao longo do tempo e se adaptam a mudanças comportamentais.

Aprendizado Semi-Supervisionado





Técnicas de Semi-Supervisão



Auto-treinamento

O modelo inicialmente treinado com dados rotulados gera previsões para dados não rotulados, incorporando aqueles com maior confiança ao conjunto de treinamento em ciclos sucessivos de aprimoramento.



Co-treinamento

Múltiplos modelos treinados em diferentes perspectivas dos dados se ensinam mutuamente, gerando pseudo-rótulos para expandir progressivamente o conjunto de treinamento.



Aprendizado Ativo

O algoritmo identifica e solicita rotulagem humana apenas para os exemplos mais informativos ou incertos, maximizando o ganho de conhecimento por anotação.




Propagação de Rótulos

Usa estrutura de grafo para disseminar rótulos conhecidos através de dados não rotulados com base em similaridade, eficaz quando dados formam clusters naturais.

Transfer Learning

Knowledge transfer between models

Ai



Professional AI
Render peasser

Professional AI
educationalization

Transfer Learning e Few-shot Learning

Pré-treinamento em Grande Escala

Modelos iniciais treinados com bilhões de parâmetros em dados massivos e diversos, desenvolvendo representações ricas e generalizáveis do mundo.

Transferência de Conhecimento

Conhecimento encapsulado nos pesos do modelo é transferido para novos domínios, eliminando a necessidade de treinamento do zero e economizando recursos computacionais.

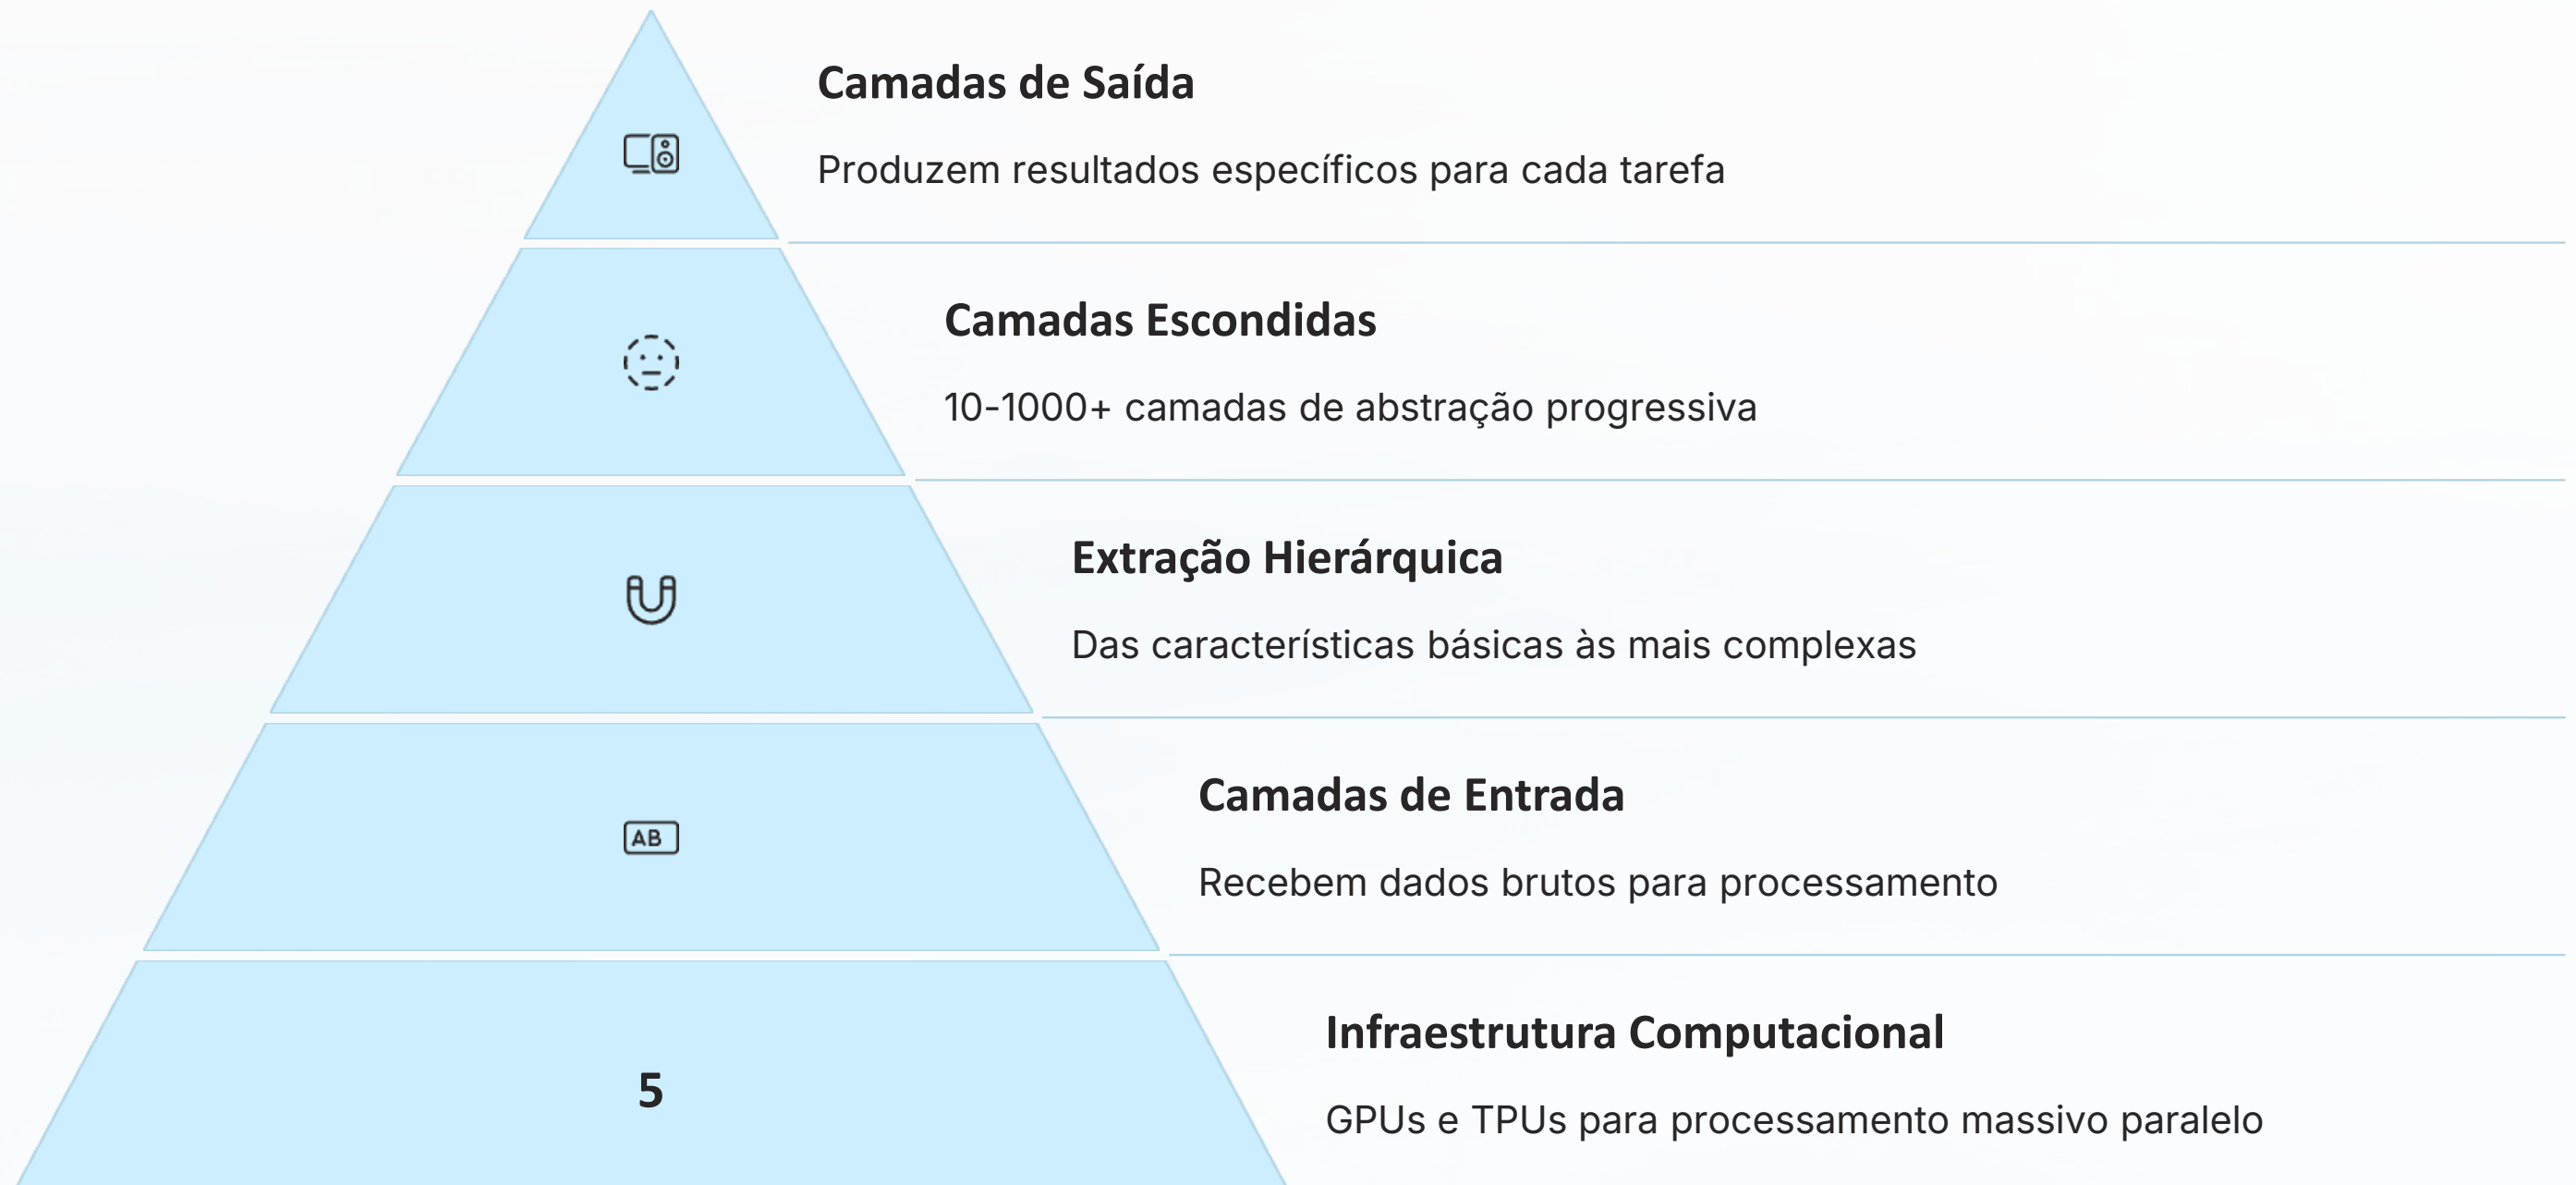
Fine-tuning Específico

Adaptação do modelo pré-treinado para tarefas específicas usando conjuntos reduzidos de dados (100-1000 exemplos), resultando em redução de 90% no tempo de treinamento.

Few-shot/Zero-shot Learning

Capacidade de generalização para tarefas com pouquíssimos exemplos (few-shot) ou até mesmo sem exemplos específicos (zero-shot), demonstrando transferência efetiva de conhecimento.

Deep Learning: Redes Neurais Profundas



Redes Neurais: Inspiração Biológica

Inspiração Biológica

Baseadas no funcionamento dos neurônios do cérebro humano, criando sistemas capazes de aprender padrões complexos.

Processamento Paralelo


Realizam múltiplos cálculos simultaneamente, permitindo análise eficiente de grandes volumes de dados.

Aprendizagem Adaptativa


Capacidade de ajustar seus parâmetros internos com base em exemplos, melhorando progressivamente seu desempenho.

Generalização

Habilidade de responder adequadamente a dados nunca vistos antes, extrapolando a partir do conhecimento adquirido.



Representação do Neurônio biológico





Terminais sinápticos: terminações que se conectam aos dendritos de outros neurônios, formando as sinapses.

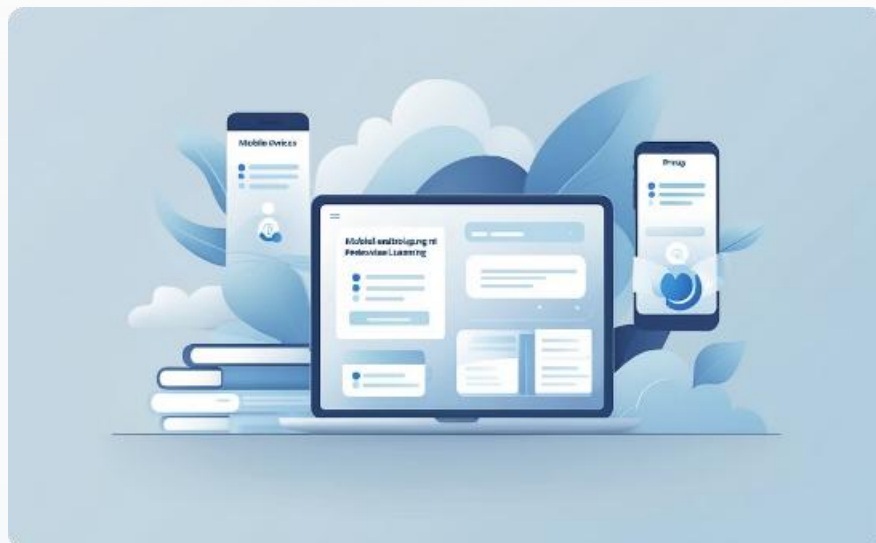
Axônio : Extensão que parte do corpo celular e leva os sinais elétricos até os terminais sinápticos.

Dentritos :extensões ramificadas do corpo celular, que se conectam aos terminais sinápticos de outros neurônios, criando as sinapses;.

Representação do Neurônio biológico



Aprendizado Federado



Preservação de Privacidade

Os dados de treinamento permanecem nos dispositivos locais dos usuários, nunca sendo compartilhados diretamente com servidores centrais, garantindo conformidade com regulamentações como LGPD.



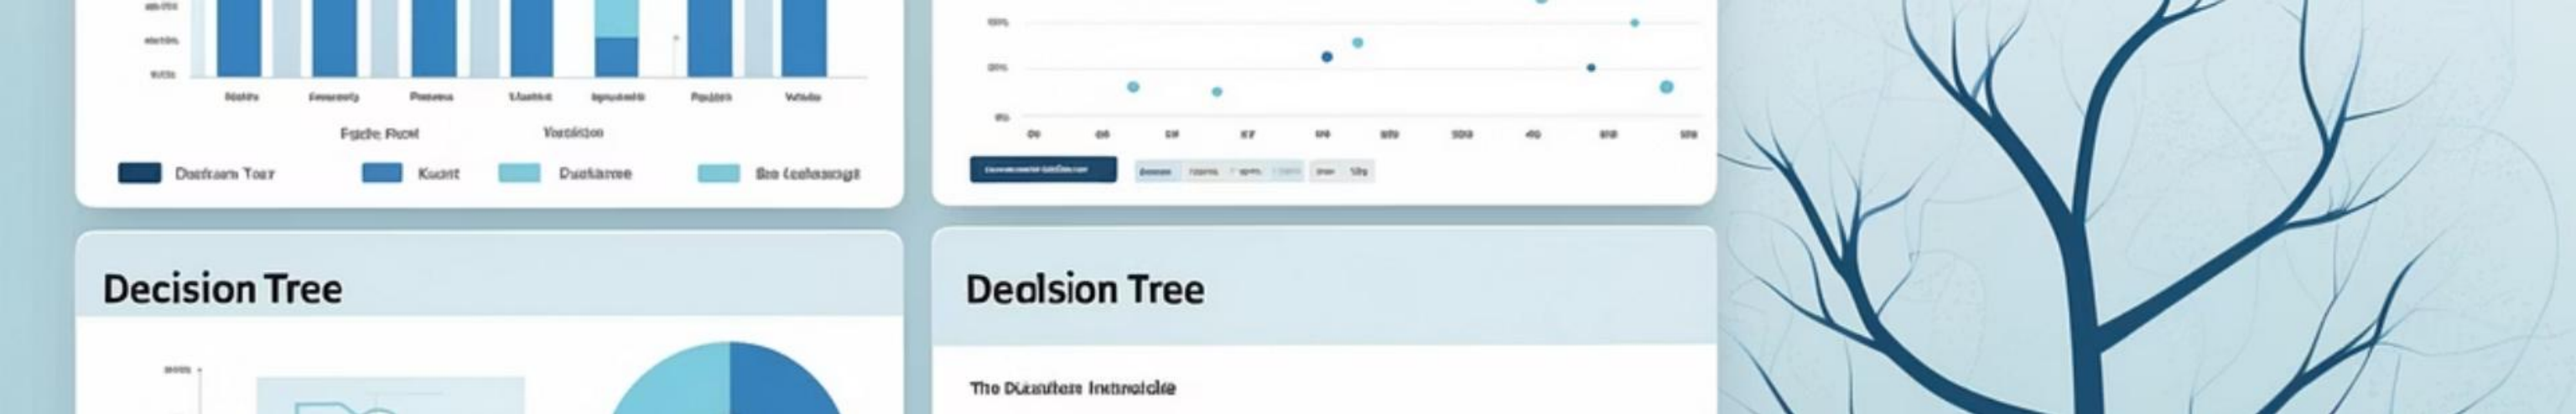
Atualizações Agregadas

Apenas as atualizações dos pesos do modelo são enviadas ao servidor central, que as agrega e distribui um modelo aprimorado, protegendo informações sensíveis individuais.



Aplicações em Setores Sensíveis

Particularmente valioso em saúde, finanças e telecomunicações, onde dados sensíveis podem melhorar modelos sem comprometer privacidade, acessando 100-1000x mais dados de treinamento.



Explainable AI (XAI)

Interpretabilidade dos Modelos

Desenvolvimento de técnicas que tornam as decisões dos modelos de aprendizado de máquina compreensíveis para humanos, especialmente crucial em aplicações de alto risco como saúde e finanças.

Técnicas de Explicação Local

Métodos como LIME (Local Interpretable Model-agnostic Explanations) e SHAP (SHapley Additive exPlanations) que explicam previsões individuais identificando contribuições de cada característica.


Visualização de Importantes

Representações visuais de características influentes nas decisões do modelo, incluindo mapas de calor para imagens e gráficos de importância para dados tabulares.

Benefícios Tangíveis

Conformidade com regulações que exigem explicabilidade em setores regulados e aumento documentado de 40% na confiança dos usuários finais em sistemas transparentes.

MLOps: Operacionalização de Machine Learning



AutoML: Democratizando o Machine Learning



Seleção Automática de Modelos

Plataformas que testam e comparam diversos algoritmos para identificar o mais adequado para cada problema específico.



Otimização de Hiperparâmetros

Exploração sistemática do espaço de configurações para maximizar o desempenho sem intervenção manual especializada.



Engenharia de Features Automatizada

Identificação, transformação e seleção inteligente de características relevantes para melhorar a qualidade das previsões.



Acessibilidade para Não-Especialistas

Interfaces intuitivas que permitem profissionais de diversos campos implementarem soluções de ML sem conhecimento profundo de algoritmos.





ARTIFICIAL INTELLIGENCE



Ética e Viés em Machine Learning



Identificação de Vieses

Métodos sistemáticos para detectar e quantificar preconceitos algorítmicos que podem perpetuar ou amplificar desigualdades sociais existentes nos dados de treinamento.



Auditoria Ética

Processo estruturado de avaliação de modelos quanto a justiça, transparência, privacidade e potenciais impactos negativos em diferentes grupos populacionais.



Transparência

Desenvolvimento de modelos explicáveis e documentação clara sobre limitações, pressupostos e funcionamento interno dos sistemas de ML implementados.



Equidade por Design

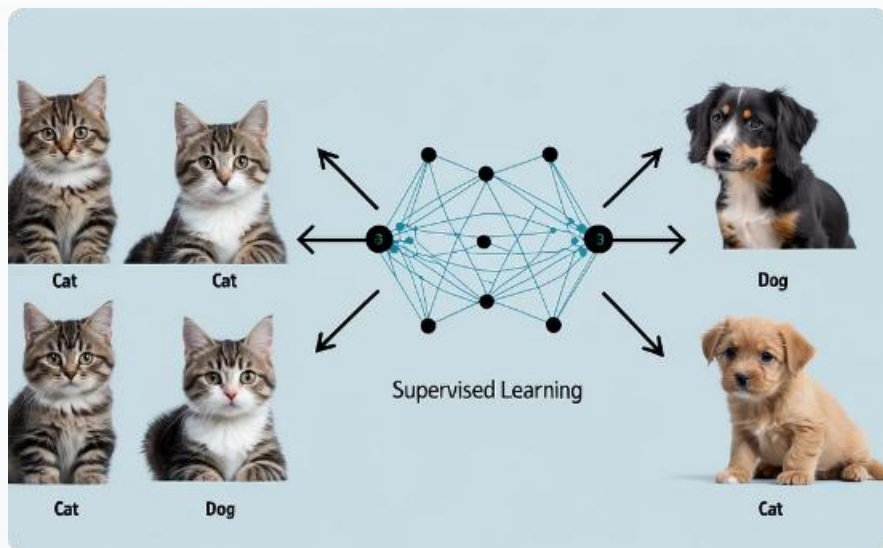
Incorporação de considerações éticas desde as fases iniciais do desenvolvimento, incluindo coleta de dados diversificados e testes de robustez em diferentes cenários sociais.

Tendências Futuras



O futuro do aprendizado de máquina promete transformações profundas em diversas frentes: sistemas de visão computacional revolucionarão varejo e segurança; processamento de linguagem natural elevará o atendimento automatizado a novos patamares; tecnologias generativas democratizarão a criação de conteúdo e arte; abordagens multimodais integrarão perfeitamente texto, imagem e áudio; enquanto avanços em computação quântica poderão oferecer ganhos de velocidade de 10-100x para problemas complexos de ML.

Conclusão: Escolhendo o Paradigma Adequado



Aprendizado Supervisionado

Ideal quando dispomos de dados rotulados em quantidade suficiente e objetivos de previsão claramente definidos. A escolha mais direta para problemas de classificação e regressão com métricas de sucesso bem estabelecidas.



Aprendizado Não Supervisionado

Preferível quando buscamos descobrir estruturas ocultas, padrões emergentes ou relações desconhecidas nos dados, sem concepções prévias sobre os agrupamentos ou categorias existentes.



Aprendizado por Reforço

Apropriado para cenários que envolvem tomada de decisões sequenciais, otimização de políticas e comportamentos adaptativos em ambientes interativos com feedback claro.



ser
educacional

OBRIGADO !



UNINASSAU



UNAMA



UNG



UNINORTE



UNIFAEI



UNI7



Grupo Ser Educacional